

16. LOGISTICKÁ REGRESE

Rovnici pro binární klasifikaci (jiné ani než 0)

- následně se kombinuje pomocí lineární kombinace působení (aka lin. regrese)

$$w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3$$

- TRIK: místa hodnoty vysvětlované proměnné $\gamma \in [0, 1]$

↳ predikujeme pravděpodobnost, že $P(\gamma=1)$ je intervalu $[0, 1]$

↳ staníme $P(\gamma=1 | x, w)$ (uvedeno, že γ je rovněž na hodnotě působení $x = (x_1, x_2, x_3)$ a $w = (w_0, w_1, w_2, w_3)$)

$$\rightarrow platí P(\gamma=1 | x, w) = 1 - P(\gamma=0 | x, w)$$

- TRIK: potřebujeme, aby $w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3$ bylo v intervalu $[0, 1]$

↳ dovedíme do vhodného využití funkce: sigmoida

- logistická funkce sigmoid: (obor hodnot: $(0, 1)$)

$$f(x) = \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}}$$

$$\lim_{x \rightarrow \infty} f(x) = 1$$

$$\lim_{x \rightarrow -\infty} f(x) = 0$$

$f(x)$... pravděpodobnost jistu $\gamma=1$

$1-f(x)$... opačný jistu

- přidáme x_0 , který má vždy $x_0 = 1$ (intercept) = očekávaná hodnota působení nulových

- napsat modelu: binární vysvětlovací proměnná γ působení x_1, x_2, \dots, x_p a konstanta $x_0 = 1$ působení w_0)

- sledování modelu ve formu

$$P(\gamma=1 | x, w) = \frac{e^{w^T x}}{1 + e^{w^T x}}$$

- predikce: pro daná x spočítáme odhad $P(\gamma=1 | x, w)$

↳ pokud $\gamma > \frac{1}{2} \Rightarrow \gamma=1$

jinak $\Rightarrow \gamma=0$

- mužnice následnou: mužnice sledování jako

$$P(\gamma=1 | x, w) = \frac{e^{w^T x}}{1 + e^{w^T x}} = \frac{1}{2} \Rightarrow w^T x = 0 \leftarrow \text{mužnice } w^T R' \text{ (lin. variabilita je } p-1\right)$$

UČENÍ MODELU

- používá se MLE (maximálně věrohodný odhad)
 - ↳ maximizuje pravděpodobnost na základě křízových dat
- MLE (příklad na hodou mincí - k. n. 1 parametru p)
 - Y... náhodná veličina hodou (0, 1)
 - $p = P(Y=1) \Rightarrow$ odhad na základě měření (křízových dat) odhadem p
měřeného dat: $\begin{matrix} 7 \times Y=1 \\ 3 \times Y=0 \end{matrix} \quad \left. \right\} \text{celkem 10 hodou}$

umíme spočítat s jeho pravděpodobností podle vztahu křízových dat pro volení p:

$$\begin{aligned} &\text{- např. pro } p = \frac{1}{2}: \quad \left(\frac{1}{2}\right)\left(\frac{1}{2}\right)^7 = 0,117 \quad \text{pravděpodobností} \\ &\text{pro } p = 0,6: \quad \left(\frac{1}{2}\right)(0,6)^7(1-0,6)^3 = 0,215 \quad (\text{lepsi p}) \end{aligned}$$

⇒ vede na hledání maxima funkce

$$L(p) = \left(\frac{1}{2}\right)p^7(1-p)^3 \quad (\text{na intervalu } p \in (0,1))$$

- 1) vzhledem konstanta $\left(\frac{1}{2}\right)$ (logaritmus ochne rovnou funkci - nevadí)
- 2) funkce logaritmujeme

$$= \ln p^7(1-p)^3 = 7 \ln p + 3 \ln(1-p) = l(p)$$

- 3) derivujeme $l(p)$:

$$l'(p) = \frac{7}{p} - \frac{3}{1-p}$$

- 4) spočítáme nutný bod:

$$p^{(MLE)} = \frac{7}{10}$$

$$\begin{aligned} &\text{- pro } p = \frac{7}{10}: \quad \left(\frac{1}{2}\right)0,7^7 \cdot (1-0,7)^3 = 0,27 \quad \leftarrow \text{maximum na křízových dotech} \\ &\quad \uparrow \text{MLE (volba } p = \frac{7}{10} \text{ má důvěryhodnost)} \end{aligned}$$

- MLE odhad pro logistickou regresi

- podobné jako pro minci (2 možnosti: Y=1; Y=0)

× máme mnohem více parametrů w_0, w_1, \dots, w_p

$$p_1(x, w) = P(Y=1|x, w) = \frac{e^{w^T x}}{1+e^{w^T x}}$$

$$p_0(x, w) = P(Y=0|x, w) = 1 - \frac{e^{w^T x}}{1+e^{w^T x}} = \frac{1}{1+e^{w^T x}}$$

- pravděpodobnost 1 datového bodu: $p_{Y_i}(x_i, w)$

- máme N datových bodů x (s průšlahy x_0, x_1, \dots, x_N)

$$\hookrightarrow X = \begin{pmatrix} x_0^T \\ x_1^T \\ \vdots \\ x_N^T \end{pmatrix} = \begin{pmatrix} 1 & w_{0,1} & w_{0,2} & \dots & w_{0,p} \\ 1 & w_{1,1} & w_{1,2} & \dots & w_{1,p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & w_{N,1} & w_{N,2} & \dots & w_{N,p} \end{pmatrix}$$

X_i jsou vysíčkované proměnné

- předpokládáme, že data jsou nezávislá \Rightarrow celkovou pravděpodobností vypočteme jeho součin

$$L(w) = \prod_{i=1}^N p_{Y_i}(x_i, w)$$

→ hled funkci se maximizovat

MAXIMALIZOVAT

- míslo derivace součinu budeme derivovat logaritmus:

$$\ell(w) = \ln L(w) = \sum_{i=1}^N \ln p_{Y_i}(x_i, w) =$$
$$= \sum_{i=1}^N (\gamma_i \ln p_1(x_i, w) + (1-\gamma_i) \ln p_0(x_i, w))$$
$$= \sum_{i=1}^N \left(\gamma_i \ln \left(\frac{e^{w^T x_i}}{1+e^{w^T x_i}} \right) + (1-\gamma_i) \ln \left(\frac{1}{1+e^{w^T x_i}} \right) \right) =$$

★ MAGIC (i vyzdášce vyřešeno)

$$= \sum_{i=1}^N \left(\gamma_i w^T x_i - \ln (1 + e^{w^T x_i}) \right)$$

chezaj najít maximum

gradient (některou složenou se parciálními derivacemi podle všech proměnných w_0, w_1, \dots, w_p)

$$\frac{\partial \ell}{\partial w_j}(w) = \sum_{i=1}^N (x_{ij} (\gamma_i - p_1(x_i, w)))$$

pro $j = 0, 1, \dots, p$

→ $\nabla \ell(w) = X^T(Y - P)$ kde $P = (p_1(x_1, w), p_1(x_2, w), \dots, p_1(x_N, w))^T$

$$\nabla \ell(w) = X^T(Y - P) = 0$$

↳ řešení (sigmoid a exponenciální)

⇒ NEVNÍME NAJÍT EXPLÍCITNÍ ŘEŠENÍ

↓
numerické approximační metody (např. grad. sekanty)